

Школа анализа данных  
Основы статистики в машинном обучении  
Домашнее задание №1

Федор Ерин

## Оценки и сходимость

### Задача 1 [2 балла]

Пусть  $X^n = \{X_1, \dots, X_n\} \sim \text{Uniform}(0, \theta)$ ,  $\hat{\theta} = \max\{X_1, \dots, X_n\}$ . Найти значения  $bias$ ,  $se$  и  $MSE$  этой оценки.

#### Решение

Заметим, что  $\hat{\theta} = \max(X_1, \dots, X_n) = X_{(n)}$ , где  $X_{(n)}$  —  $n$ -ая порядковая статистика. Найдем эмпирическую функцию распределения для  $\hat{\theta}$ :

$$\hat{F}_n(X_{(n)}) = \mathbb{P}(X_{(n)} < x) = \mathbb{P}(X_1 < x)^n = \begin{cases} \frac{x^n}{\theta^n}, & x \in [0, \theta] \\ 1, & x > \theta \\ 0, & x < 0 \end{cases}$$

Зная  $\hat{F}_n(X_{(n)})$ , найдем по определению 1 и 2 моменты, а затем  $bias$ ,  $se$ ,  $MSE$ :

$$\mathbb{E}X_{(n)} = \int_0^\theta x d\hat{F}_n(X_{(n)}) = \int_0^\theta xn \frac{x^{n-1}}{\theta^n} dx = \frac{n}{\theta^n} \frac{1}{n+1} (x^{n+1}) \Big|_0^\theta = \frac{n}{n+1} \theta$$

$$\mathbb{E}X_{(n)}^2 = \int_0^\theta x^2 d\hat{F}_n(X_{(n)}) = \frac{n}{\theta^n} \frac{1}{n+2} (x^{n+2}) \Big|_0^\theta = \frac{n}{n+2} \theta^2$$

$$bias = \mathbb{E}\hat{\theta} - \theta = \frac{n}{n+1} \theta - \theta = -\frac{\theta}{n+1}$$

$$\mathbb{V}X_{(n)} = \mathbb{E}X_{(n)}^2 - (\mathbb{E}X_{(n)})^2 = \frac{n}{n+2} \theta^2 - \frac{n^2}{(n+1)^2} \theta^2 = \frac{n\theta^2(n+1)^2 - n^2\theta^2(n+2)}{(n+2)(n+1)^2} = \frac{n\theta^2}{(n+2)(n+1)^2}$$

$$se = \sqrt{\mathbb{V}X_{(n)}} = \frac{\theta}{n+1} \sqrt{\frac{n}{n+2}}$$

$$MSE = bias^2 + se^2 = \frac{\theta^2}{(n+1)^2} + \frac{n\theta^2}{(n+2)(n+1)^2} = \frac{2\theta^2}{(n+1)(n+2)}$$

**Ответ:**  $bias = -\frac{\theta}{n+1}$ ,  $se = \frac{\theta}{n+1} \sqrt{\frac{n}{n+2}}$ ,  $MSE = \frac{2\theta^2}{(n+1)(n+2)}$ .

## Задача 2 [2 балла]

Пусть  $X^n = \{X_1, \dots, X_n\} \sim \text{Exp}(\lambda)$ ,  $\hat{\lambda} = 1/\bar{X}^n$ . Найдите  $\text{bias}$ ,  $\text{se}$ ,  $\text{MSE}$  этой оценки. Является ли оценка смещенной? Состоятельной?

### Решение

Заметим, что  $X_i \sim \text{Exp}(\lambda) = \Gamma(1, \frac{1}{\lambda})$ . По свойству гамма-распределения:

$$\sum_{i=1}^n X_i \sim \Gamma(\sum_{i=1}^n 1, \frac{1}{\lambda}) = \Gamma(n, \frac{1}{\lambda})$$

Известна плотность гамма-распределения:

$$\gamma(x) = \begin{cases} \frac{\lambda^n}{\Gamma(n)} x^{n-1} e^{-\lambda x}, & x > 0 \\ 0, & x \leq 0 \end{cases}$$

Теперь можем найти по определению 1 и 2 моменты, а затем  $\text{bias}$ ,  $\text{se}$ ,  $\text{MSE}$ :

$$\begin{aligned} \mathbb{E} \frac{1}{\bar{X}^n} &= \mathbb{E} \frac{n}{\sum_{i=1}^n X_i} = n \int_0^\infty \frac{1}{x} \frac{\lambda^n}{(n-1)!} x^{n-1} e^{-\lambda x} dx = \\ &= \frac{\lambda n}{(n-1)!} \int_0^\infty (\lambda x)^{n-2} e^{-\lambda x} d(\lambda x) = \frac{\lambda n}{(n-1)!} \Gamma(n-1) = \frac{\lambda n}{(n-1)!} (n-2)! = \frac{n}{n-1} \lambda \\ \mathbb{E} \frac{1}{(\bar{X}^n)^2} &= \mathbb{E} \frac{n^2}{(\sum_{i=1}^n X_i)^2} = n^2 \int_0^\infty \frac{1}{x^2} \frac{\lambda^n}{(n-1)!} x^{n-1} e^{-\lambda x} dx = \\ &= \frac{\lambda^2 n^2}{(n-1)!} \int_0^\infty (\lambda x)^{n-3} e^{-\lambda x} d(\lambda x) = \frac{\lambda^2 n^2}{(n-1)!} \Gamma(n-2) = \frac{\lambda^2 n^2}{(n-1)!} (n-3)! = \frac{\lambda^2 n^2}{(n-1)(n-2)} \\ \text{bias} &= \mathbb{E} \hat{\lambda} - \lambda = \frac{n}{n-1} \lambda - \lambda = \frac{\lambda}{n-1} \neq 0 \Rightarrow \text{оценка смещенная} \end{aligned}$$

$$\mathbb{V} \hat{\lambda} = \mathbb{E} \frac{1}{(\bar{X}^n)^2} - \left( \mathbb{E} \frac{1}{\bar{X}^n} \right)^2 = \frac{\lambda^2 n^2}{(n-1)(n-2)} - \frac{\lambda^2 n^2}{(n-1)^2} = \frac{\lambda^2 n^2 (n-1) - \lambda^2 n^2 (n-2)}{(n-1)^2 (n-2)} = \frac{\lambda^2 n^2}{(n-1)^2 (n-2)}$$

$$\text{se} = \sqrt{\mathbb{V} \hat{\lambda}} = \frac{\lambda n}{(n-1) \sqrt{n-2}}$$

$$\text{MSE} = \text{bias}^2 + \text{se}^2 = \frac{\lambda^2}{(n-1)^2} + \frac{\lambda^2 n^2}{(n-1)^2 (n-2)} = \frac{\lambda^2 (n-2) + \lambda^2 n^2}{(n-1)^2 (n-2)} = \frac{\lambda^2 (n^2 + n - 2)}{(n-1)^2 (n-2)} = \frac{\lambda^2 (n+2)}{(n-1)(n-2)}$$

$$\text{bias} = \frac{\lambda}{n-1} \rightarrow 0, \text{se} = \frac{\lambda n}{(n-1) \sqrt{n-2}} \rightarrow 0 \text{ при } n \rightarrow \infty \Rightarrow \text{оценка состоятельна.}$$

**Ответ:**  $\text{bias} = \frac{\lambda}{n-1}$ ,  $\text{se} = \frac{\lambda n}{(n-1) \sqrt{n-2}}$ ,  $\text{MSE} = \frac{\lambda^2 (n+2)}{(n-1)(n-2)}$ , смещенная, состоятельна.

## Эмпирическая функция распределения

### Задача 3 [2 балла]

Пусть  $\hat{F}_n(x)$  — эмпирическая функция распределения. Пусть  $x, y \in \mathbb{R}$ . Найдите ковариацию  $Cov(\hat{F}_n(x), \hat{F}_n(y))$ .

#### Решение

Используя  $\hat{F}_n(x) = \frac{1}{n} \sum_{i=1}^n I(X_i \leq x)$  и  $\mathbb{E}\hat{F}_n(x) = F(x)$ , распишем по определению ковариацию:

$$\begin{aligned} Cov(\hat{F}_n(x), \hat{F}_n(y)) &= \\ &= \mathbb{E}[(\hat{F}_n(x) - \mathbb{E}\hat{F}_n(x))(\hat{F}_n(y) - \mathbb{E}\hat{F}_n(y))] = \\ &= \mathbb{E}[\hat{F}_n(x) \cdot \hat{F}_n(y)] - \mathbb{E}\hat{F}_n(x) \cdot \mathbb{E}\hat{F}_n(y) = \\ &= \frac{1}{n^2} \mathbb{E}\left[\sum_{i=1}^n I(X_i \leq x) \cdot \sum_{j=1}^n I(X_j \leq y)\right] - F(x) \cdot F(y) = \\ &= \frac{1}{n^2} \mathbb{E}\left[\sum_{i=j} I(X_i \leq x) I(X_i \leq y) + \sum_{i \neq j} I(X_i \leq x) I(X_j \leq y)\right] - F(x) \cdot F(y) = \\ &= \frac{1}{n^2} [nF(\min(x, y)) + n(n-1)F(x)F(y)] - F(x) \cdot F(y) = \\ &= \frac{F(\min(x, y)) - F(x)F(y)}{n} \end{aligned}$$

**Ответ:**  $Cov(\hat{F}_n(x), \hat{F}_n(y)) = \frac{F(\min(x, y)) - F(x)F(y)}{n}$ .

### Задача 4 [2 балла]

Пусть  $X^n = \{X_1, \dots, X_n\} \sim F(x)$ , и пусть  $\hat{F}_n(x)$  — эмпирическая функция распределения. Для фиксированных числе  $a, b \in \mathbb{R}$ , таких что  $a < b$  определим статистический функционал  $T(F) = F(b) - F(a)$ . Пусть  $\hat{\theta} = \hat{F}_n(b) - \hat{F}_n(a)$ . Найдите оценку  $\hat{se}$  стандартного отклонения и  $(1 - \alpha)$ -доверительный интервал.

#### Решение

Найдем  $\hat{se}$  для  $\hat{\theta}$ , используя  $\mathbb{V}\hat{F}_n(x) = \frac{F(x)(1-F(x))}{n}$  и полученную в задаче 3 формулу для ковариации:

$$\begin{aligned} \hat{se}^2 &= \mathbb{V}\hat{\theta} = \mathbb{V}(\hat{F}_n(b) - \hat{F}_n(a)) = \mathbb{V}\hat{F}_n(b) + \mathbb{V}\hat{F}_n(a) - 2Cov(\hat{F}_n(b), \hat{F}_n(a)) = \\ &= \frac{F(b)(1-F(b))}{n} + \frac{F(a)(1-F(a))}{n} - 2\frac{F(\min(a, b)) - F(a)F(b)}{n} = \\ &= \frac{1}{n} [F(b) - F^2(b) + F(a) - F^2(a) - 2F(a) + 2F(a)F(b)] = \\ &= \frac{1}{n} [F(b) - F(a) - (F(b) - F(a))^2] = \\ &= \frac{T(F)(1-T(F))}{n}. \end{aligned}$$

Возьмем оценку  $T(F) = T(\hat{F}_n)$ , откуда  $\hat{se}^2 = \frac{T(\hat{F}_n)(1-T(\hat{F}_n))}{n}$ .

Так как  $T(\hat{F}_n) \sim N(T(F), \hat{se}^2)$ , то  $(1 - \alpha)$ -доверительный интервал будет иметь вид:

$$(T(\hat{F}_n) - z_{1-\alpha/2} \cdot \hat{se}, T(\hat{F}_n) + z_{1-\alpha/2} \cdot \hat{se})$$

**Ответ:**  $(T(\hat{F}_n) - z_{1-\alpha/2} \cdot \hat{se}, T(\hat{F}_n) + z_{1-\alpha/2} \cdot \hat{se})$ , где  
 $T(\hat{F}_n) = \hat{F}_n(b) - \hat{F}_n(a)$ ,  
 $\hat{se} = \sqrt{\frac{T(\hat{F}_n)(1-T(\hat{F}_n))}{n}}$ ,  
 $z_{1-\alpha/2}$  – квантиль стандартного нормального распределения.

## Бутстреп

### Задача 8 [3 балла]

Пусть  $X^n = \{X_1, \dots, X_n\} \sim N(\mu, \sigma^2)$ ,  $\theta = e^\mu$  и  $\hat{\theta} = e^{\bar{X}^n}$ . Найдите аналитически плотность распределения  $p_{\hat{\theta}}(x)$  оценки  $\hat{\theta} = e^{\bar{X}^n}$ , математическое ожидание  $\mathbb{E}(\hat{\theta})$ , и дисперсию  $\mathbb{V}(\hat{\theta})$ , а также  $bias$ ,  $se$ ,  $MSE$  оценки  $\hat{\theta}$ . Является ли оценка  $\hat{\theta}$  смещенной? Состоятельной?

#### Решение

Если  $X_i \sim N(\mu, \sigma^2)$ , то  $e^{X_i} \sim LnN(\mu, \sigma^2)$  – логнормальное распределение. Известна плотность такого распределения:

$$p(x) = \frac{1}{x\sigma\sqrt{2\pi}} \exp\left(-\frac{(\log x - \mu)^2}{2\sigma^2}\right)$$

Усредненная сумма  $n$  одинаковых нормально распределенных случайных величин  $N(\mu, \sigma^2)$  распределена как  $N(\mu, \sigma^2/n)$ , следовательно  $\hat{\theta} = e^{\bar{X}^n}$  распределена как  $LnN(\mu, \sigma^2/n)$  с плотностью распределения:

$$p_{\hat{\theta}}(x) = \frac{\sqrt{n}}{x\sigma\sqrt{2\pi}} \exp\left(-\frac{n(\log x - \mu)^2}{2\sigma^2}\right)$$

Используя известные матожидание и дисперсию логнормального распределения, получаем:

$$\mathbb{E}(\hat{\theta}) = \mathbb{E}[X \sim LnN(\mu, \sigma^2/n)] = e^{\mu + \sigma^2/2n}$$

$$\mathbb{V}(\hat{\theta}) = \mathbb{V}[X \sim LnN(\mu, \sigma^2/n)] = e^{2\mu + \sigma^2/n}(e^{\sigma^2/n} - 1)$$

$$bias = \mathbb{E}(\hat{\theta}) - \theta = e^{\mu + \sigma^2/2n} - e^\mu = e^\mu(e^{\sigma^2/2n} - 1) \neq 0 \Rightarrow \text{оценка смещенная}$$

$$se = \sqrt{\mathbb{V}(\hat{\theta})} = \sqrt{e^{2\mu + \sigma^2/n}(e^{\sigma^2/n} - 1)} = e^{\mu + \sigma^2/2n} \sqrt{e^{\sigma^2/n} - 1}$$

$$MSE = bias^2 + se^2 = e^{2\mu}(e^{\sigma^2/2n} - 1)^2 + e^{2\mu + \sigma^2/n}(e^{\sigma^2/n} - 1) = e^{2\mu}(e^{\sigma^2/2n} - 1)(e^{\sigma^2/2n} - 1 + e^{\sigma^2/n})$$

$$bias = e^\mu(e^{\sigma^2/2n} - 1) \rightarrow 0, se = e^{\mu + \sigma^2/2n} \sqrt{e^{\sigma^2/n} - 1} \rightarrow 0 \text{ при } n \rightarrow \infty \Rightarrow \text{оценка состоятельна.}$$

**Ответ:**  $p_{\hat{\theta}}(x) = \frac{\sqrt{n}}{x\sigma\sqrt{2\pi}} \exp\left(-\frac{n(\log x - \mu)^2}{2\sigma^2}\right)$ ,  $\mathbb{E}(\hat{\theta}) = e^{\mu + \sigma^2/2n}$ ,  $\mathbb{V}(\hat{\theta}) = e^{2\mu + \sigma^2/n}(e^{\sigma^2/n} - 1)$ ,  $bias = e^\mu(e^{\sigma^2/2n} - 1)$ ,  $se = e^{\mu + \sigma^2/2n} \sqrt{e^{\sigma^2/n} - 1}$ ,  $MSE = e^{2\mu}(e^{\sigma^2/2n} - 1)(e^{\sigma^2/2n} - 1 + e^{\sigma^2/n})$ , смещенная, состоятельна.